

WiFi CSI People Detection

Themenbereiche: WiFi Sensing, Machine Learning, 3D-Pose-Schätzung, Personendetektion

Studierender: Fabian Stettler

Dozent: Prof. Dr. Björn Jensen

Experte: Kai Waelti

Auftraggeber: HSLU AI Robotics Research Lab

Keywords: WiFi CSI, Channel State Information, 3D-Pose-Schätzung, Personendetektion, Transformer, OpenWrt, Intel RealSense, Machine Learning

1. Kurzfassung der Aufgabenstellung

Die Erkennung von Personen ist ein zentraler Baustein für die Mensch-Maschine-Interaktion. Kamerabasierte Systeme sind lichtabhängig und werfen in sensiblen Umgebungen Datenschutzfragen auf. Als Alternative bietet sich WiFi-basiertes Sensing an: Channel State Information (CSI) erfasst, wie sich elektromagnetische Signale im Raum ausbreiten und wie Bewegungen diese Signale verändern.

Im Robotics Lab der HSLU wurde in einer Vorgängerarbeit bereits die grundsätzliche Machbarkeit gezeigt. Ziel dieser Bachelorarbeit war es, Personen allein aus WiFi-Signalen zu erkennen und deren Körperstellung räumlich zu lokalisieren. Konkret sollten für einen definierten Raum die 3D-Koordinaten von 14 Körperlandmarks einer einzelnen Person vorhergesagt werden. Dafür mussten CSI-Daten erfasst, mit Referenzdaten synchronisiert, ein Trainingsdatensatz aufgebaut und geeignete Machine-Learning-Modelle trainiert, evaluiert und miteinander verglichen werden.

2. Vorgehen / Lösungskonzept

Die Arbeit folgte einer klassisch sequenziellen Vorgehensweise: Literaturrecherche, Konzeption, Datenerfassung, Modellentwicklung, Training, Evaluation und Dokumentation.

Für die Datenerfassung wurde ein Setup aus vier TP-Link Archer C7 Routern mit Atheros-Chipsatz aufgebaut: ein Transmitter und drei Receiver. Nach dem Flashen von OpenWrt wurden CSI-Daten per UDP an eine Workstation übertragen.




Abbildung 1: *

Netzwerkaufbau: Ein Transmitter sendet WiFi-Pakete, drei Receiver lesen CSI-Daten aus und leiten sie an die Workstation weiter.

Als Ground Truth diente eine Intel RealSense Kamera in Kombination mit MediaPipe. Aus RGB- und Tiefenbildern wurden 2D-Landmarks extrahiert und in 3D-Koordinaten transformiert. Eine regelbasierte Nachbearbeitung reduzierte Tiefenrauschen, anatomisch unplausible Gelenkwinkel und kurzfristige Sprünge in den Referenzdaten.

Die Synchronisation zwischen Kamera und Routern erfolgte über NTP. Pro Sample wurden 21 CSI-Zeitschritte

den zugehörigen 3D-Posen zugeordnet und als Tokens der Form (3 Router, 3 Antennen, 21 Zeitschritte, 56 Subcarrier) exportiert. Das Datenset umfasst 94'703 Samples (11,9 GB) mit vielfältigen Bewegungsmustern wie Bücken, Dehnübungen, Sportübungen, Gehen und Sitz-Stand-Wechsel.

Zwei Modellarchitekturen wurden implementiert und verglichen:

- das Transformer-basierte Referenzmodell von Yan et al. für CSI-basierte 3D-Pose-Schätzung;
- eine eigene CNN-Attention-Diffusion-Architektur (CTD), die CSI-Daten zuerst mit einem CNN-Encoder tokenisiert, zeitliche Abhängigkeiten in einem Attention-Block modelliert und die Vorhersage in einem Diffusions-Refiner nachkorrigiert.

3. Spezielle Herausforderungen

Ein zentrales Risiko war die Erzeugung qualitativ hochwertiger 3D-Ground-Truth-Koordinaten. Die rohen Posen aus der Kamerapipeline wiesen Tiefenrauschen, Sprünge und anatomisch unplausible Gelenkstellungen auf. Dieses Risiko wurde durch eine mehrstufige Refinement-Pipeline mit Skelett-Normalisierung, Gelenkwinkel-Constraints und temporaler Glättung entschärft.

Das Matching von Kamera- und CSI-Daten erforderte präzise Zeitstempel. Dafür wurden globale Time-stamps direkt auf den Receiver-Routern erzeugt und die Uhren vor jeder Aufnahmesession per NTP mit der Workstation synchronisiert.

Beim Starten der Router-Infrastruktur traten wiederholt WLAN-Verbindungsprobleme auf. Diese liessen sich durch ein festes Startprotokoll, manuelles Ausführen des Sendeskripts und Log-Überwachung per SSH beheben.

Ein erster Trainingsversuch scheiterte, weil die 56 Subcarrier der verwendeten Hardware auf 30 Werte interpoliert und leere Sequenzen mittrainiert wurden. Erst nach Anpassung der Architektur auf 56 Subcarrier und dem Entfernen leerer Sequenzen verbesserte sich die Modellgüte deutlich.

Das gewählte Setup mit drei Receivern war aufwändiger als ein einfacher Sender-Empfänger-Aufbau, erlaubte aber deutlich mehr und vielfältigere Daten pro Aufnahme und eine bessere Vergleichbarkeit mit dem Stand der Forschung.

4. Konkrete Ergebnisse

Im Rahmen der Bachelorarbeit wurden folgende Ergebnisse erarbeitet:

- **Messinfrastruktur:** Vollständiges CSI-Erfassungssystem mit vier Routern, Datenerfassungs-Skripten, NTP-Synchronisation und Export-Pipeline.
- **Trainingsdatensatz:** 94'703 synchronisierte CSI-Pose-Samples für einen konkreten Raum im Robotics Lab (S12, Zimmer 13).
- **Zwei trainierte Modelle:** Yan-Referenzmodell und eigenes CTD-Modell auf demselben Datensatz.
- **Live-Framework:** Softwarekomponente für Echtzeit-Tokenisierung und Visualisierung von Modellvorhersagen.

Eine statistische Voranalyse bestätigte, dass sich die Amplitudenvarianz der CSI-Signale unterscheidet, wenn sich eine Person im Raum befindet oder nicht. Damit wurde die Eignung von Machine-Learning-Modellen für die Poseschätzung belegt.

Beide Modelle wurden auf demselben Testdatensatz evaluiert (MPJPE als Fehlermass):

- **Yan-Modell:** mittlerer MPJPE 201,84 mm, ca. 13,1 Mio. Parameter, Trainingsdauer 30 Stunden.
- **CTD-Modell:** mittlerer MPJPE 111,87 mm, ca. 3,1 Mio. Parameter, Trainingsdauer 15 Stunden.




Abbildung 2: *

Beispielhafte Modellvorhersage: Grün = Ground Truth, Blau = CTD-Modell, Orange = Yan-Modell.

Das CTD-Modell erzielte damit die besseren Resultate bei deutlich weniger Parametern. Der Diffusions-Refiner verbesserte die Attention-Vorhersage messbar, blieb aber insgesamt moderat. Für vorbereitete Testdaten funktioniert das Live-Framework zuverlässig; bei verändertem Router-Setup bricht die Live-Inferenz ein.

Die formulierten Ziele wurden erreicht: Es wurde gezeigt, dass aus WiFi-Signalen die 3D-Position einzelner Körperlandmarks einer Person in einem konkreten Raum vorhergesagt werden kann.

5. Ausblick

Für weiterführende Arbeiten bieten sich mehrere Richtungen an. Ein zentraler Punkt ist die Verbesserung der Generalisierung auf neue Räume und veränderte Router-Layouts. Neuere Ansätze wie PerceptAlign zeigen, dass die explizite Einbindung der Gerätegeometrie in ein gemeinsames Koordinatensystem die Cross-Layout-Performance deutlich verbessern kann.

Als weiterer Ansatz für Domain-Shift über mehrere Räume hinweg bietet sich *Nested Learning* an: CSI-Tokens könnten genutzt werden, um Modellparameter situationsabhängig anzupassen, statt ein fixes, raumspezifisches Mapping zu memorieren.

Schliesslich wäre eine Erweiterung von der Einzelpersonen- auf die Mehrpersonen-Schätzung interessant, wofür die Yan-Architektur grundsätzlich ausgelegt ist. Dafür bräuchte es jedoch zusätzliche Trainingsdaten und angepasste Evaluationsprotokolle. Insgesamt bleibt WiFi-basierte 3D-Pose-Schätzung ein aktives Forschungsfeld mit hohem Potenzial für datenschutzfreundliche Anwendungen, sofern Robustheit, Setup-Unabhängigkeit und praktische Deploybarkeit weiter verbessert werden.